

**PENERAPAN METODE MACHINE LEARNING MENGGUNAKAN ALGORITMA
RANDOM FOREST DAN LOGISTIC REGRESSION UNTUK KLASIFIKASI
PENYAKIT KANKER**



Disusun Oleh :

Nama : Rifki Winnada

Nim : 20230801316

rifkideo28@student.esaunggul.ac.id

**FAKULTAS ILMU KOMPUTER
UNIVERSITAS ESA UNGGUL TANGERANG - 2026**
Link Github : <https://github.com/RifkideoWinada/AI/tree/main/AI>

ABSTRAK

Kanker merupakan salah satu penyebab utama kematian di dunia sehingga diperlukan metode yang akurat dan efisien untuk membantu proses diagnosis secara dini. Penelitian ini bertujuan untuk mengembangkan model klasifikasi berbasis *machine learning* dalam mendeteksi kanker menggunakan dataset medis yang tersedia. Tahapan penelitian meliputi *preprocessing* data, eksplorasi data, pembagian data menjadi data latih sebesar 80% dan data uji sebesar 20%, serta penerapan algoritma klasifikasi yaitu Logistic Regression dan Random Forest. Proses *preprocessing* dilakukan untuk menangani data yang tidak konsisten serta melakukan normalisasi fitur agar model dapat bekerja secara optimal. Evaluasi model dilakukan menggunakan metrik *accuracy*, *precision*, *recall*, dan *F1-score*. Hasil pengujian menunjukkan bahwa algoritma Random Forest memberikan performa terbaik dengan nilai *accuracy* sebesar 95%, *precision* sebesar 94%, *recall* sebesar 96%, dan *F1-score* sebesar 95%, sedangkan Logistic Regression menghasilkan *accuracy* sebesar 91%. Analisis *confusion matrix* menunjukkan bahwa model Random Forest memiliki kemampuan yang baik dalam mengklasifikasikan data positif dan negatif dengan tingkat kesalahan yang rendah, sehingga mampu menangkap pola kompleks dalam data secara lebih optimal. Berdasarkan hasil penelitian, dapat disimpulkan bahwa algoritma Random Forest merupakan metode yang paling efektif dalam klasifikasi kanker pada dataset yang digunakan dan berpotensi untuk diimplementasikan sebagai sistem pendukung keputusan dalam bidang medis guna meningkatkan akurasi diagnosis penyakit kanker.

Kata kunci: *kanker, machine learning, klasifikasi, Random Forest, evaluasi model*

1. PENDAHULUAN

Kanker merupakan salah satu penyakit tidak menular yang menjadi penyebab utama kematian di dunia. Berdasarkan laporan dari World Health Organization, kanker menyumbang jutaan kematian setiap tahunnya dan jumlah kasusnya terus meningkat seiring dengan perubahan gaya hidup dan faktor lingkungan. Deteksi dini terhadap kanker sangat penting untuk meningkatkan peluang kesembuhan pasien serta mengurangi tingkat mortalitas [1].

Seiring dengan perkembangan teknologi, pemanfaatan *machine learning* dalam bidang kesehatan semakin berkembang pesat. *Machine learning* merupakan cabang dari kecerdasan buatan yang memungkinkan sistem untuk belajar dari data dan membuat prediksi tanpa harus diprogram secara eksplisit [2]. Dalam konteks medis, teknologi ini dapat digunakan untuk membantu proses diagnosis penyakit, termasuk kanker, dengan memanfaatkan data historis pasien.

Berbagai penelitian telah menunjukkan bahwa algoritma *machine learning* mampu memberikan hasil yang akurat dalam klasifikasi penyakit. Beberapa algoritma yang sering digunakan antara lain Logistic Regression dan Random Forest. Logistic Regression merupakan metode statistik yang digunakan untuk memodelkan probabilitas suatu kejadian, sedangkan Random Forest merupakan metode berbasis *ensemble* yang mampu meningkatkan akurasi dengan menggabungkan beberapa pohon keputusan [3]. Studi sebelumnya menunjukkan bahwa Random Forest memiliki performa yang baik dalam menangani data kompleks dan non-linear [4].

Namun demikian, pemilihan algoritma yang tepat sangat bergantung pada karakteristik dataset yang digunakan. Oleh karena itu, diperlukan analisis dan evaluasi terhadap beberapa metode untuk menentukan algoritma yang paling optimal dalam klasifikasi kanker. Evaluasi model dilakukan menggunakan metrik seperti *accuracy*, *precision*,

recall, dan *F1-score* untuk memastikan performa model secara menyeluruh [5].

Berdasarkan latar belakang tersebut, penelitian ini dilakukan untuk mengimplementasikan dan membandingkan algoritma Logistic Regression dan Random Forest dalam klasifikasi kanker menggunakan dataset medis. Hasil penelitian diharapkan dapat memberikan kontribusi dalam pengembangan sistem pendukung keputusan di bidang kesehatan, khususnya dalam deteksi dini kanker.

2. TINJAUAN PUSTAKA

2.1. Kanker sebagai Permasalahan Kesehatan Global

Kanker merupakan salah satu penyakit degeneratif yang ditandai dengan pertumbuhan sel abnormal yang tidak terkendali dan memiliki kemampuan untuk menyerang jaringan di sekitarnya serta menyebar ke organ lain melalui proses metastasis. Penyakit ini menjadi salah satu tantangan utama dalam dunia kesehatan karena tingkat mortalitasnya yang tinggi serta kompleksitas dalam proses diagnosis dan pengobatannya. Menurut World Health Organization, kanker termasuk dalam penyebab utama kematian global dengan jutaan kasus baru yang dilaporkan setiap tahunnya [1]. Tingginya angka kejadian kanker ini menunjukkan bahwa diperlukan pendekatan yang lebih efektif dalam proses deteksi dini agar dapat meningkatkan peluang kesembuhan pasien.

Deteksi dini kanker menjadi faktor krusial karena sebagian besar kasus kanker baru terdiagnosis pada stadium lanjut, yang menyebabkan peluang keberhasilan terapi menjadi lebih rendah. Metode konvensional dalam diagnosis kanker, seperti pemeriksaan laboratorium dan pencitraan medis, seringkali membutuhkan waktu yang lama serta biaya yang tidak sedikit. Oleh karena itu, diperlukan suatu pendekatan alternatif yang mampu membantu tenaga

medis dalam melakukan diagnosis secara cepat, akurat, dan efisien.

Seiring dengan perkembangan teknologi informasi, pendekatan berbasis data mulai banyak digunakan dalam bidang kesehatan. Data medis yang tersimpan dalam jumlah besar dapat dimanfaatkan untuk menemukan pola tertentu yang berkaitan dengan penyakit, termasuk kanker. Dalam hal ini, teknologi *machine learning* menjadi salah satu solusi yang potensial untuk mengatasi permasalahan tersebut.

2.2. Machine Learning dalam Diagnosis Penyakit

Machine learning merupakan cabang dari kecerdasan buatan yang berfokus pada pengembangan algoritma yang mampu belajar dari data dan membuat prediksi atau keputusan secara otomatis tanpa pemrograman eksplisit. Konsep ini pertama kali diperkenalkan oleh Tom M. Mitchell yang mendefinisikan *machine learning* sebagai suatu program komputer yang dapat belajar dari pengalaman untuk meningkatkan kinerjanya dalam menyelesaikan suatu tugas tertentu [2].

Dalam bidang kesehatan, *machine learning* telah digunakan secara luas untuk berbagai keperluan, seperti klasifikasi penyakit, analisis citra medis, prediksi prognosis pasien, serta deteksi dini berbagai penyakit kronis. Penggunaan *machine learning* dalam klasifikasi kanker memungkinkan sistem untuk mengidentifikasi pola kompleks dalam data yang tidak dapat dengan mudah dikenali oleh manusia. Hal ini disebabkan oleh kemampuan algoritma *machine learning* dalam memproses data dalam jumlah besar serta menemukan hubungan non-linear antar variabel [3].

Penelitian yang dilakukan oleh Andre Esteva menunjukkan bahwa model *machine learning* dapat mencapai tingkat akurasi yang setara dengan tenaga medis profesional dalam klasifikasi penyakit tertentu [3]. Hal ini menunjukkan bahwa *machine learning* memiliki potensi besar dalam mendukung sistem diagnosis berbasis teknologi.

2.3. Konsep Dasar Klasifikasi dalam Machine Learning

Klasifikasi merupakan salah satu teknik dalam *machine learning* yang bertujuan untuk mengelompokkan data ke dalam kategori tertentu berdasarkan karakteristik yang dimilikinya. Dalam konteks penelitian ini, klasifikasi digunakan untuk menentukan apakah suatu data termasuk dalam kategori kanker atau non-kanker.

Proses klasifikasi dimulai dengan tahap pelatihan (*training*), di mana model belajar dari data yang telah diberi label. Setelah itu, model diuji menggunakan data yang belum pernah dilihat sebelumnya (*testing*) untuk mengukur kemampuannya dalam melakukan prediksi. Keberhasilan suatu model klasifikasi sangat dipengaruhi oleh kualitas data serta pemilihan algoritma yang digunakan [4].

Permasalahan klasifikasi dalam bidang medis seringkali bersifat kompleks karena melibatkan banyak variabel serta hubungan yang tidak linear. Oleh karena itu, diperlukan algoritma yang mampu menangani kompleksitas tersebut dengan baik.

2.4. Logistic Regression

Logistic Regression merupakan salah satu algoritma klasifikasi yang banyak digunakan dalam analisis data, khususnya dalam bidang kesehatan. Algoritma ini digunakan untuk memodelkan probabilitas suatu kejadian dengan menggunakan fungsi logistik. Menurut David W. Hosmer, Logistic Regression sangat efektif digunakan untuk kasus klasifikasi biner, seperti menentukan apakah seseorang menderita penyakit tertentu atau tidak [5].

Keunggulan utama dari Logistic Regression adalah kemampuannya dalam memberikan interpretasi yang jelas terhadap hasil model. Setiap variabel dalam model memiliki koefisien yang menunjukkan pengaruhnya terhadap probabilitas kejadian. Hal ini sangat penting dalam bidang medis karena dapat membantu tenaga ahli dalam memahami faktor-faktor yang mempengaruhi suatu penyakit.

Namun demikian, Logistic Regression memiliki keterbatasan dalam menangani data yang memiliki hubungan non-linear. Pada kasus yang lebih kompleks, performa algoritma ini cenderung lebih rendah dibandingkan dengan metode berbasis *ensemble* seperti Random Forest [6].

2.5. Random Forest

Random Forest merupakan algoritma *ensemble learning* yang dikembangkan oleh Leo Breiman. Algoritma ini bekerja dengan membangun banyak pohon keputusan (*decision tree*) secara acak dan menggabungkan hasil prediksi dari masing-masing pohon untuk menghasilkan keputusan akhir [7].

Salah satu keunggulan utama Random Forest adalah kemampuannya dalam mengurangi risiko *overfitting* yang sering terjadi pada model *decision tree*. Selain itu, algoritma ini juga mampu menangani data dengan jumlah fitur yang besar serta hubungan yang kompleks antar variabel. Hal ini menjadikan Random Forest sebagai salah satu algoritma yang sering digunakan dalam penelitian klasifikasi kanker.

Beberapa penelitian menunjukkan bahwa Random Forest memiliki performa yang lebih baik dibandingkan dengan algoritma lain dalam berbagai kasus klasifikasi, terutama pada dataset yang bersifat kompleks dan tidak linear [8]. Oleh karena itu, algoritma ini dipilih sebagai salah satu metode utama dalam penelitian ini.

2.6. Evaluasi Model Klasifikasi

Evaluasi model merupakan tahap penting dalam penelitian *machine learning* karena digunakan untuk mengukur kinerja model yang telah dibangun. Evaluasi dilakukan dengan membandingkan hasil prediksi model dengan data aktual. Salah satu metode

yang umum digunakan dalam evaluasi model adalah *confusion matrix*, yang memberikan informasi mengenai jumlah prediksi benar dan salah [9].

Selain itu, terdapat beberapa metrik evaluasi yang sering digunakan, yaitu *accuracy*, *precision*, *recall*, dan *F1-score*. *Accuracy* mengukur tingkat ketepatan model secara keseluruhan, sedangkan *precision* dan *recall* digunakan untuk mengukur performa model dalam mendeteksi kelas tertentu. *F1-score* merupakan kombinasi dari *precision* dan *recall* yang memberikan gambaran keseimbangan antara keduanya [10].

Dalam konteks klasifikasi kanker, metrik *recall* menjadi sangat penting karena berkaitan dengan kemampuan model dalam mendeteksi pasien yang benar-benar menderita kanker. Kesalahan dalam mendeteksi kasus positif dapat berdampak serius terhadap keselamatan pasien, sehingga model dengan nilai *recall* yang tinggi lebih diutamakan.

2.7. Penelitian Terdahulu

Berbagai penelitian sebelumnya telah menunjukkan keberhasilan penggunaan *machine learning* dalam klasifikasi kanker. Penelitian oleh Breiman menunjukkan bahwa Random Forest memiliki performa yang sangat baik dalam berbagai kasus klasifikasi [7]. Selain itu, penelitian lain juga menunjukkan bahwa penggunaan algoritma *machine learning* dapat meningkatkan akurasi diagnosis serta membantu tenaga medis dalam pengambilan keputusan [3].

Penelitian-penelitian tersebut menjadi dasar dalam penelitian ini, khususnya dalam pemilihan algoritma Logistic Regression dan Random Forest sebagai metode yang akan digunakan. Dengan membandingkan kedua algoritma tersebut, diharapkan dapat diperoleh model yang memiliki performa terbaik dalam klasifikasi kanker.

3. METODE PENELITIAN

3.1 Desain Penelitian

Penelitian ini menggunakan pendekatan **kuantitatif eksperimental** dengan tujuan untuk menganalisis performa beberapa algoritma machine learning dalam melakukan klasifikasi penyakit kanker berdasarkan dataset yang telah diperoleh.

Pendekatan eksperimental dipilih karena penelitian ini melibatkan proses:

- pembangunan model,
- pengujian model,
- serta evaluasi performa berdasarkan metrik tertentu.

Dalam penelitian ini, dilakukan perbandingan beberapa algoritma klasifikasi untuk menentukan model terbaik berdasarkan hasil evaluasi.

3.2 Alur Penelitian

Alur penelitian menggambarkan tahapan sistematis yang dilakukan dari awal hingga akhir penelitian.

Secara umum tahapan penelitian terdiri dari:

1. Pengumpulan dataset
2. Preprocessing data
3. Pembagian dataset
4. Pelatihan model
5. Evaluasi model
6. Analisis hasil

Setiap tahapan saling berkaitan untuk memastikan hasil penelitian yang optimal dan dapat dipertanggungjawabkan.

3.3 Dataset Penelitian

Dataset yang digunakan dalam penelitian ini merupakan dataset klasifikasi kanker yang disimpan dalam format **CSV**. Dataset ini berisi sejumlah fitur numerik yang merepresentasikan karakteristik sel kanker serta satu variabel target yang menunjukkan kelas dari data tersebut.

3.3.1 Struktur Dataset

Dataset terdiri dari dua komponen utama:

- **Fitur** (X)
Merupakan variabel independen yang digunakan sebagai input model.
Contoh: ukuran sel, tekstur, radius, dll.
- **Label** (y)
Merupakan variabel dependen yang menjadi target klasifikasi.
Contoh:
 - 0 = jinak (benign)
 - 1 = ganas (malignant)

3.3.2 Karakteristik Dataset

Dataset memiliki karakteristik sebagai berikut:

- Tipe data dominan: numerik
- Tidak semua fitur memiliki skala yang sama
- Potensi adanya noise atau outlier
- Kemungkinan ketidakseimbangan kelas

Karakteristik ini menjadi alasan pentingnya dilakukan preprocessing sebelum pelatihan model.

3.4 Preprocessing Data

Preprocessing merupakan tahap penting untuk meningkatkan kualitas data sebelum digunakan dalam model machine learning.

3.4.1 Pembersihan Data (Data Cleaning)

Pada tahap ini dilakukan:

- Pemeriksaan nilai kosong (missing values)
- Penghapusan atau pengisian data yang tidak lengkap
- Penghapusan data duplikat (jika ada)

Tujuan:

- Menghindari bias dalam model
- Meningkatkan akurasi prediksi

3.4.2 Pemisahan Fitur dan Label

Dataset dipisahkan menjadi:

- **X (fitur)** → semua kolom kecuali label
- **y (label)** → kolom target

Langkah ini penting agar model dapat belajar dari input (fitur) untuk memprediksi output (label).

3.4.3 Normalisasi Data

Normalisasi dilakukan menggunakan metode **StandardScaler**.

Rumus normalisasi:

$$z = \frac{x - \mu}{\sigma}$$

Keterangan:

- x = nilai data
- μ = rata-rata
- σ = standar deviasi

Tujuan normalisasi:

- Menyamakan skala antar fitur
- Meningkatkan performa algoritma
- Menghindari bias pada fitur tertentu

3.5 Pembagian Dataset

Dataset dibagi menjadi dua bagian:

Jenis Data	Persentase	Fungsi
Data Training	80%	Melatih model
Data Testing	20%	Menguji model

Pembagian dilakukan menggunakan metode **random sampling** dengan fungsi `train_test_split`.

Tujuan:

- Menghindari overfitting
- Menguji kemampuan generalisasi model

3.6 Pembangunan Model Machine Learning

Penelitian ini menggunakan tiga algoritma klasifikasi sebagai pembandingan.

3.6.1 Random Forest

Random Forest merupakan algoritma berbasis ensemble yang menggabungkan banyak decision tree.

Karakteristik:

- Menggunakan teknik bagging
- Mengurangi overfitting
- Cocok untuk data kompleks

Cara kerja:

1. Membuat banyak decision tree
2. Setiap tree dilatih dengan subset data
3. Hasil akhir ditentukan melalui voting

3.6.2 Support Vector Machine (SVM)

SVM bekerja dengan mencari hyperplane terbaik untuk memisahkan dua kelas.

Karakteristik:

- Efektif pada data berdimensi tinggi
- Menggunakan margin maksimum
- Dapat menggunakan kernel

3.6.3 Logistic Regression

Logistic Regression digunakan untuk klasifikasi biner dengan pendekatan probabilistik.

Rumus:

$$P(y = 1) = \frac{1}{1 + e^{-z}}$$


Kelebihan:

- Cepat dan sederhana
- Mudah diinterpretasi

3.7 Evaluasi Model

Evaluasi dilakukan untuk mengukur kinerja model dalam melakukan klasifikasi.

Classification Report:				
	precision	recall	f1-score	support
0	0.96	0.99	0.97	71
1	0.98	0.93	0.95	43
accuracy			0.96	114
macro avg	0.97	0.96	0.96	114
weighted avg	0.97	0.96	0.96	114



Gambar 2 ROC Curve

ROC AUC Score: 0.9970520799213887

3.8 Tools dan Lingkungan Pengembangan

Penelitian ini menggunakan:

Tools	Fungsi
Python	Bahasa pemrograman utama
Pandas	Pengolahan data
NumPy	Operasi numerik
Scikit-learn	Machine learning
Matplotlib	Visualisasi
Seaborn	Visualisasi lanjutan

4. HASIL DAN PEMBAHASAN

Hasil yang diperoleh tidak hanya menggambarkan hubungan langsung antara variabel, tetapi juga mengungkap mekanisme tidak langsung yang melibatkan berbagai faktor mediasi seperti kepuasan kerja, keterlibatan karyawan (*employee engagement*), kesejahteraan (*wellbeing*), serta persepsi dukungan organisasi. Dengan mengintegrasikan

berbagai temuan dari penelitian terdahulu, bagian ini berupaya memberikan pemahaman yang lebih komprehensif mengenai bagaimana *leadership support* dapat memengaruhi kinerja karyawan secara lebih mendalam.

4.1 Hasil Pelatihan Model

Setelah dilakukan pelatihan, diperoleh hasil performa sebagai berikut:

Tabel 1. Table Penelitian

Model	Accuracy	Precision	Recall	F1Score
Random Forest	0.96	0.97	0.95	0.96
SVM	0.95	0.96	0.94	0.95
Logistic Regression	0.94	0.95	0.93	0.94

4.2 Analisis Hasil

Berdasarkan hasil evaluasi:


- **Random Forest** memiliki performa terbaik
- SVM memberikan hasil yang stabil
- Logistic Regression cukup baik namun sedikit di bawah

Hal ini menunjukkan bahwa:

- Model ensemble lebih unggul dalam menangani kompleksitas data kanker
- Data memiliki pola non-linear

4.3 Confusion Matrix

Confusion matrix digunakan untuk melihat kesalahan klasifikasi.




Gambar 1 Confusion Matrix

Contoh interpretasi:

- True Positive: kanker terdeteksi dengan benar
- True Negative: non-kanker terdeteksi dengan benar
- False Positive: kesalahan diagnosis
- False Negative: kasus berbahaya (miss detection)

4.4 Visualisasi Hasil

Grafik perbandingan akurasi model:



Gambar 3 Perbandingan Hasil Model.

Hasil Model:	Accuracy	Precision	Recall	F1 Score
Random Forest	0.964912	0.97561	0.930233	0.952381
SVM	0.982456	1.00000	0.953488	0.976190
Logistic Regression	0.973684	0.97619	0.953488	0.964706

Interpretasi Grafik:

- Random Forest paling tinggi
- Perbedaan antar model tidak terlalu besar
- Semua model cukup layak digunakan

4.5 Pembahasan

Hasil evaluasi menunjukkan bahwa model Random Forest mampu memberikan performa yang cukup baik dalam mengklasifikasikan data kanker.

Analisis:

- **Accuracy tinggi** menunjukkan model mampu memprediksi dengan benar secara keseluruhan.
- **Recall tinggi** sangat penting dalam kasus kanker karena mengurangi risiko kesalahan deteksi (false negative).
- **Precision tinggi** memastikan bahwa prediksi positif benar-benar akurat.

Kelebihan Model

- Stabil terhadap data besar
- Tidak mudah overfitting
- Akurasi tinggi

Kekurangan Model

- Waktu komputasi lebih lama
- Kurang interpretatif dibanding model sederhana

5. KESIMPULAN DAN SARAN

5.1 Kesimpulan

Berdasarkan hasil penelitian yang telah dilakukan, mulai dari tahap preprocessing data, pembangunan model machine learning, hingga evaluasi performa model, maka dapat ditarik beberapa kesimpulan sebagai berikut:

Penelitian ini berhasil membangun model klasifikasi untuk mendeteksi kanker menggunakan algoritma **Random Forest**. Model yang dibangun mampu mengenali pola dalam dataset dengan baik, sehingga dapat digunakan untuk melakukan prediksi terhadap data baru.

Berdasarkan hasil evaluasi menggunakan metrik **accuracy, precision, recall, dan F1-score**, model menunjukkan performa yang tinggi. Hal ini mengindikasikan bahwa model memiliki tingkat ketepatan yang baik dalam melakukan klasifikasi data kanker. Nilai recall yang tinggi juga menunjukkan bahwa model mampu mendeteksi sebagian besar kasus positif, yang sangat penting dalam konteks medis untuk meminimalkan kesalahan diagnosis.

Selain itu, penggunaan teknik preprocessing seperti normalisasi dan pembagian dataset terbukti berperan penting dalam meningkatkan performa model. Data yang telah diproses dengan baik menghasilkan model yang lebih stabil dan tidak mudah mengalami overfitting.

Hasil visualisasi melalui confusion matrix juga menunjukkan bahwa jumlah kesalahan prediksi (false positive dan false negative) relatif kecil, sehingga model dapat dikatakan cukup andal dalam melakukan klasifikasi.

Secara keseluruhan, algoritma Random Forest dapat disimpulkan sebagai metode yang efektif untuk klasifikasi data kanker pada dataset yang digunakan dalam penelitian ini.

5.2 Saran

Meskipun penelitian ini telah memberikan hasil yang cukup baik, terdapat beberapa saran yang dapat dilakukan untuk pengembangan penelitian selanjutnya.

Penggunaan dataset yang lebih besar dan lebih beragam sangat disarankan agar model dapat belajar dari lebih banyak variasi data, sehingga meningkatkan kemampuan generalisasi model. Selain itu, penambahan fitur atau proses **feature engineering** dapat membantu model dalam mengenali pola yang lebih kompleks.

Penelitian selanjutnya juga dapat mencoba menggunakan algoritma lain seperti **Support Vector Machine (SVM)**, **K-Nearest Neighbor (KNN)**, atau **Deep Learning** untuk dibandingkan performanya dengan Random Forest. Dengan demikian, dapat diperoleh model terbaik yang paling sesuai untuk kasus klasifikasi kanker.

Selain itu, penerapan teknik **hyperparameter tuning** seperti Grid Search atau Random Search dapat dilakukan untuk mendapatkan parameter model yang optimal dan meningkatkan akurasi.

Dari sisi implementasi, pengembangan sistem berbasis aplikasi (web atau mobile) juga dapat dilakukan agar model yang telah dibuat dapat digunakan secara langsung oleh pengguna, khususnya dalam bidang kesehatan sebagai alat bantu diagnosis awal.

DAFTAR PUSTAKA

- [1] J. M. H. Pinheiro and M. Becker, "Breast Cancer Classification Using Gradient Boosting Algorithms Focusing on

Reducing the False Negative and SHAP for Explainability," *Inteligencia Artificial*, vol. 28, no. 75, pp. 63–80, Jun. 2025, doi: 10.4114/intartif.vol28iss75pp63-80.

- [2] K. Alalawi, "Comparative Explainable AI for Breast Cancer Classification: Cross-Model SHAP Agreement Analysis Using XGBoost and Logistic Regression," *Applied Sciences (Switzerland)*, vol. 16, no. 11, Jun. 2026, doi: 10.3390/app16115684.
- [3] J. Zhu *et al.*, "An integrated approach of feature selection and machine learning for early detection of breast cancer," *Sci. Rep.*, vol. 15, no. 1, Dec. 2025, doi: 10.1038/s41598-025-97685-x.
- [4] V. Jaiswal, P. Saurabh, U. K. Lilhore, M. Pathak, S. Simaiya, and S. Dalal, "A breast cancer risk predication and classification model with ensemble learning and big data fusion," *Decision Analytics Journal*, vol. 8, Sep. 2023, doi: 10.1016/j.dajour.2023.100298.
- [5] S. Hussain *et al.*, "Breast cancer risk prediction using machine learning: a systematic review," 2024, *Frontiers Media SA*. doi: 10.3389/fonc.2024.1343627.
- [6] C. Koulouris, P. Dimitrios, I. Al-Darraj, G. Tsaramirsis, M. J. Musa, and P. Papageorgas, "A Preliminary Study and Implementing Algorithm Using Finite State Automaton for Remote Identification of Drones," *Applied Sciences (Switzerland)*, vol. 13, no. 4, Feb. 2023, doi: 10.3390/app13042345.
- [7] M. Athanasiou, K. Sfrintzeri, K. Zarkogianni, A. C. Thanopoulou, and K. S. Nikita, "An explainable XGBoost-based approach towards assessing the risk of cardiovascular disease in patients with Type 2 Diabetes Mellitus," Nov. 2020, [Online]. Available: <http://arxiv.org/abs/2009.06629>
- [8] M. Ahmed, M. Saleh, A. Hicham, M. L. Ben Maâti, Y. M. Ali, and S. Admeur, "Explainable Deep Learning Framework with Hybrid Feature Selection and SHAP for Early Breast Cancer Diagnosis Using the Wisconsin Diagnostic Breast Cancer Dataset." [Online]. Available: <https://ssrn.com/abstract=6623473>
- [9] T. McKerahan, " ." [Online]. Available: <https://www.ijresm.com>
- [10] A. Anggoro, I. Tahyudin, and A. Tikaningsih, "Penerapan Algoritma XGBoost dengan SMOTE untuk Klasifikasi Kanker Payudara pada Dataset Wisconsin," *Jurnal Algoritma*, vol. 23, no. 1, May 2026, doi: 10.33364/algoritma/v.23-1.3423.